

TP N°2 - Extract / Transform / Load

Description :

Le TP vise à vous familiariser avec les étapes essentielles de l'extraction, de la préparation et du nettoyage des données à l'aide de la bibliothèque Python Pandas. Vous apprendrez à charger des données depuis un fichier CSV dans un DataFrame, à inspecter et explorer les données, à identifier et à traiter les valeurs manquantes et les doublons, ainsi qu'à effectuer des analyses avancées sur les données.

Jeu de données :

Jeu de données utilisé : Nous utiliserons un jeu de données fictif représentant les ventes mensuelles d'une entreprise, avec des informations telles que le nom du produit, la quantité vendue, le chiffre d'affaires, la date de vente, etc.

Table : ventes_mensuelles

```
+-----+
|                ventes_mensuelles                |
+-----+
| id (INT, PRIMARY KEY)                           |
| nom_produit (VARCHAR(100))                       |
| quantite_vendue (INT)                            |
| chiffre_affaires (DECIMAL(10, 2))                |
| date_vente (DATE, NOT NULL)                      |
+-----+
```

- `id` : Identifiant unique de la vente (clé primaire).
- `nom_produit` : Le nom du produit vendu (chaîne de caractères, maximum 100 caractères).
- `quantite_vendue` : La quantité de produits vendus (entier, non nul).
- `chiffre_affaires` : Le chiffre d'affaires réalisé pour cette vente (nombre décimal, précision de 10 chiffres avec 2 décimales, non nul).
- `date_vente` : La date de la vente (au format DATE, non nulle).

Énoncé des questions :

1. Charger le jeu de données dans une structure de données Pandas (DataFrame).
2. Afficher les premières lignes du DataFrame pour inspecter les données.
3. Combien de lignes et de colonnes contient le DataFrame ?
4. Vérifier s'il y a des valeurs manquantes dans le jeu de données et traiter ces valeurs le cas échéant.

5. Calculer le chiffre d'affaires total réalisé par l'entreprise sur l'ensemble du jeu de données.
6. Quel est le produit le plus vendu ? Combien d'unités ont été vendues ?
7. Créer une nouvelle colonne "Mois" dérivée de la colonne de dates et regrouper les données par mois. Calculer le chiffre d'affaires moyen par mois.
8. Afficher les ventes mensuelles moyennes pour chaque produit sous forme de graphique.
9. Trouver les dates où le chiffre d'affaires est supérieur à la moyenne mensuelle et les afficher.
10. Exporter le DataFrame nettoyé dans un nouveau fichier CSV.

Pour aller plus loin

1. Afficher le top 5 des produits qui ont enregistré le plus grand nombre de ventes en un mois.
2. Calculer le pourcentage de croissance du chiffre d'affaires d'un mois à l'autre et afficher les résultats.
3. Calculer le nombre total de produits différents vendus chaque mois.
4. Créer une nouvelle colonne "Trimestre" basée sur la colonne de dates et regrouper les données par trimestre. Créer un graphique adapté pour comparer les performances de vente des produits entre les années.
5. Proposer une méthode pour gérer les doublons éventuels dans les données et les supprimer.