

TD_0 Apprentissage non-supervisé : Partitionnement

La bibliothèque *numpy* sera utilisée pour représenter les listes ainsi que les jeux de données en *Python*. Le package *scikit-learn* sera également utilisé pour l'apprentissage automatique. Les étapes sont à effectuer les unes après les autres, ne passez à l'étape suivante que si vous avez terminé la précédente. Pensez à utiliser la *feuille de triche* fournie en annexe, qui vous simplifiera la vie !

Partie 1 : Les K-Moyennes

Exercice 1

Chargez le jeu de données IRIS. Cependant, cette fois-ci nous n'allons travailler qu'avec deux variables du jeu de données ; la longueur des pétales et la largeur des pétales. Pour cela, après avoir chargé vos données vous pouvez simplement écrire $X = X[:, 2 :]$. Vous allez travailler avec des modèles qui utilisent la notion de distance, pensez donc toujours à standardiser vos données avant d'entraîner un modèle !

Affichez le jeu de données sous forme d'un nuage de points pour ces deux variables. Qu'observez-vous pour les différentes classes ?

Exercice 2

Nous allons travailler en apprentissage non-supervisé, la variable y qui représente la vraie classe pour chaque iris ne sera donc pas utilisée.

Initialisez un modèle des K-moyennes avec $K = 3$, affichez la prédiction du modèle sous forme d'un nuage de points et comparez le résultat avec la vraie classe de chaque observation, le modèle a-t-il fait trois classes qui correspondent aux vraies classes Setosa, Versicolor et Virginica ?

Que pouvez-vous conclure ?

Exercice 3

Programmez une boucle qui calcule l'inertie totale du modèle pour 2 à 10 classes. Affichez la courbe de perte d'inertie en fonction du nombre de classes et avec la méthode du coude, choisissez un nombre de classes qui vous semble pertinent. Est-ce que ce nombre correspond au nombre réel de classes de ce jeu de données ?

Que pouvez-vous conclure ?

Partie 2 : Classification ascendante hiérarchique

Exercice 1

Sur le jeu de données IRIS complet, réalisez une CAH et affichez le dendrogramme associé. Une méthode parfois utilisée pour définir un nombre de classes sans a priori est de couper le

dendrogramme là où votre ligne de séparation est la plus éloignée de toute intersection. Combien de classes obtenez-vous avec cette méthode ?

Exercice 2

Réalisez la même opération sur le jeu de données *BreastCancer*.

Partie 2 : Attrapez-les tous

Pour les deux jeux de données étudiés, nous avons accès à la vraie classe des observations, cependant en apprentissage non supervisé, l'objectif est de faire des regroupements sans avoir accès à une quelconque classe. C'est pourquoi vous allez travailler sur un jeu de données pour lequel il n'existe pas de "vérité terrain", l'objectif est de partitionner les données de la manière la plus pertinente possible. Pour cette partie nous ne travaillerons plus avec *numpy*, mais avec *pandas* pour la gestion des données.

Exercice 1

Décrivez succinctement le jeu de données *pokemon.csv*.

Chargez le jeu de données dans un *dataframe* et sélectionnez uniquement les 18 premières colonnes. Essayez de partitionner ce jeu avec les K-moyennes, affichez la courbe de perte d'inertie pour plusieurs valeurs de K.

Exercice 2

Choisissez une valeur pertinente de K et affichez les 10 premiers pokemons de chaque classe ainsi formée, vous afficherez les variables *nom*, *type1* et *type2* pour chaque pokemon. Le regroupement vous paraît cohérent ?