

TD Système de recommandation

6 novembre 2023

Calculer la similarité entre les profils de deux clients, entre deux produits, permet d'identifier les centres d'intérêt "proches". Ainsi, plus la "distance" entre deux "objets" est petite, plus la similarité est grande, i.e. plus ils sont similaires. Pour réaliser une recommandation on peut alors procéder de la sorte :

- calculer les similarités entre les objets
- trier les objets dans l'ordre décroissant
- retourner les N premiers objets pertinents

1 Préliminaires : vecteurs d'attributs

Considérons une collection d'objets (utilisateur, produits...). Soit A l'ensemble ordonné de tous les attributs (mots clés) décrivant les objets. Nous représentons alors chaque objet par un vecteur de dimension $|A|$, contenant, pour chaque coordonnée, le poids de l'attribut correspondant dans la description de l'objet.

Exemple : Nous prenons dans cet exemple le cas de recommandation de film (mais ne vous inquiétez pas on n'ira pas plus loin).

Film F1

Jurassic World, 2015

Action, Aventure, Sci-Fi

Film F2

Ant-Man, 2015

Action, Comédie, Sci-Fi

Nous considérons dans cet exemple les genres comme mots clés : Action, Aventure, Comédie, Crime, Drama, Sci-Fi. Les vecteurs de ces films et de la requête seront donc numérisés ainsi :

$$F1 = (1, 1, 0, 0, 0, 1)$$

$$F2 = (1, 0, 1, 0, 0, 1)$$

Cas d'étude : Soit les produits suivants (choisi arbitrairement) :

Produit R

Le Hobbit

Bilbo, comme tous les hobbits, est un petit être paisible et sans histoire. Son quotidien est bouleversé un beau jour, lorsque Gandalf le magicien et treize nains barbus l'entraînent dans un voyage périlleux. C'est le début d'une grande aventure, d'une fantastique quête au trésor semée d'embûches et d'épreuves, qui mènera Bilbo jusqu'à la Montagne Solitaire gardée par le dragon Smaug...

Produit J

Dungeons & Dragons

Le jeu de rôle Dungeons & Dragons consiste à narrer des aventures dans des mondes peuplés de guerriers et de magiciens. Tout comme les jeux où l'on s'amuse à faire semblant, D&D repose sur l'imagination. Dans ce monde fantastique, les possibilités sont infinies.

Quels mots clés utiliserez-vous pour ces produits ?

Proposez les vecteurs d'attributs de R et J.

2 Des mesures de similarité

Plusieurs mesures de similarités existent, nous en proposons 3 ici, mais libre à vous d'en chercher d'autres par curiosité.

2.1 Similarité du cosinus

La similarité du cosinus calcule le produit scalaire des deux vecteurs divisé par le produit des normes des deux vecteurs.

$$SimCos(R, J) = \frac{R.J}{|R| * |J|} \quad (1)$$

Pour rappel la norme d'un vecteur R de dimension n est calculé comme suit:

$$|R| = \sqrt{r_1^2 + r_2^2 + \dots + r_n^2}$$

Et le produit scalaire de deux vecteurs R et J de dimension n :

$$R.J = r_1 * j_1 + r_2 * j_2 + \dots + r_n * j_n$$

2.2 Similarité sur la distance euclidienne

La distance euclidienne entre deux vecteurs R et J de dimension n est

$$DE(R, J) = \sqrt{(r_1 - j_1)^2 + (r_2 - j_2)^2 + \dots + (r_n - j_n)^2} \quad (2)$$

Pour en faire une similarité, on peut considérer par exemple : $\frac{1}{DE(R,J)}$. Attention, veuillez à considérer l'éventualité d'une distance nulle.

2.3 Coefficient de Jaccard

Le coefficient de Jaccard est défini comme étant le quotient du cardinal de l'intersection par celui de l'union.

$$Jacc(R, J) = \frac{|R \cap J|}{|R \cup J|} \quad (3)$$

Calculez avec les trois mesures proposées la similarité de R et J.

3 Des systèmes de recommandation basiques

Nous avons vu qu'il existe 3 types de systèmes de recommandation : *model-based*, *user-based*, *item-based*. Nous nous concentrons dans ce TD sur les deux derniers car ils sont plus simple à réaliser et à exploiter pour une utilisation en temps réelle.

3.1 User based

La recommandation *user-based* repose sur les informations données par l'utilisateur (u), ses préférences, ses goûts. Les utilisateurs vont être regroupés et des items (i) aimés par des utilisateurs au profil similaire (v_k) seront proposés :

$$prediction(u, i) = \frac{\sum_k note(v_k, i) * sim(v_k, u)}{\sum_k sim(v_k, u)} \quad (4)$$

Dans l'équation ci-dessus $note(v_k, i)$ est la note donnée par l'utilisateur v_k à l'item i et $sim(v_k, u)$ est une mesure de similarité entre les utilisateurs u et v_k .

3.2 Item based

La recommandation *item-based* permet de se référer aux caractéristiques des items (j_l) aimés par l'utilisateur pour construire des sous groupes d'items similaires.

$$prediction(u, i) = \frac{\sum_l note(u, j_l) * sim(j_l, i)}{\sum_l sim(j_l, i)} \quad (5)$$

Dans l'équation ci-dessus $note(u, j_l)$ est la note donnée par l'utilisateur u à l'item j_l et $sim(j_l, i)$ est une mesure de similarité entre les items j_l et i .

Créez des utilisateurs, produits et notes pour réaliser quelques recommandations.

Pour les utilisateurs vous pouvez avoir comme mots clés par exemple : le type de produit acheté, la catégorie d'âge, s'il a des avantages...